

15

Singular Value Decomposition

奇异值分解

最重要的矩阵分解，没有之一



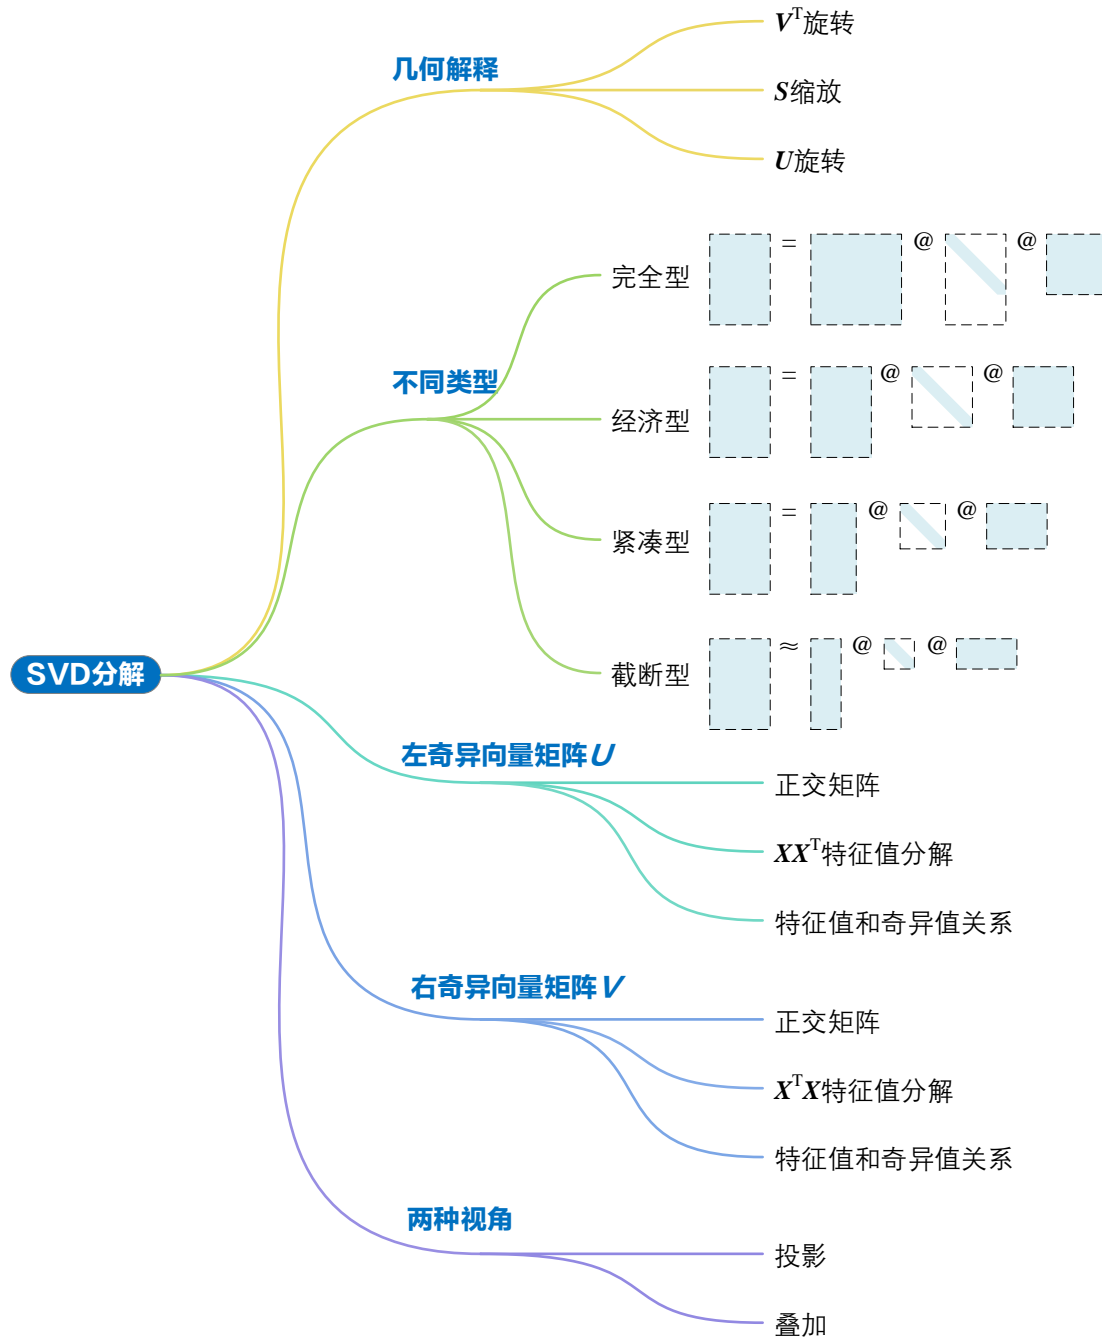
就我而言，我一无所知，但满眼的繁星让我入梦。

For my part I know nothing with any certainty, but the sight of the stars makes me dream.

—— 文森特·梵高 (Vincent van Gogh) | 荷兰后印象派画家 | 1853 ~ 1890



- ◀ `matplotlib.pyplot.quiver()` 绘制箭头图
- ◀ `numpy.linspace()` 在指定的间隔内，返回固定步长的数据
- ◀ `numpy.linalg.svd()` 进行 SVD 分解
- ◀ `numpy.diag()` 以一维数组的形式返回方阵的对角线元素，或将一维数组转换成对角阵



15.1 几何视角：旋转 → 缩放 → 旋转

本书第 11 章简要介绍过**奇异值分解** (Singular Value Decomposition, SVD) —— 宇宙中最重要的矩阵分解。本节将从几何视角解剖奇异值分解。

对数据矩阵 $\mathbf{X}_{n \times D}$ 奇异值分解得到：

$$\mathbf{X}_{n \times D} = \mathbf{U} \mathbf{S} \mathbf{V}^T \quad (1)$$

其中， \mathbf{S} 为对角阵，其主对角线元素 $s_j (j = 1, 2, \dots, D)$ 为**奇异值** (singular value)。

⚠ 注意，SVD 分解得到的奇异值非负，即 $s_j \geq 0$ 。此外注意，(1) 中矩阵 \mathbf{V} 的转置运算。

\mathbf{U} 的列向量称作**左奇异向量** (left singular vector)。

\mathbf{V} 的列向量称作**右奇异向量** (right singular vector)。

SVD 分解有四种主要形式，完全型是其中一种。在完全型 SVD 分解中， \mathbf{U} 和 \mathbf{V} 为正交矩阵，即 \mathbf{U} 和自己转置 \mathbf{U}^T 的乘积为单位矩阵； \mathbf{V} 和自己转置 \mathbf{V}^T 的乘积也是单位矩阵。

从向量空间角度来看， $\mathbf{U} = [\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_n]$ 为 \mathbb{R}^n 的规范正交基， $\mathbf{V} = [\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_D]$ 为 \mathbb{R}^D 的规范正交基。

根据这三个矩阵的形态，我们知道，从几何视角来看，正交矩阵 \mathbf{U} 和 \mathbf{V} 矩阵作用是旋转，而对角矩阵 \mathbf{S} 的作用是缩放。

大家可能会问这和特征值分解对应的“旋转 → 缩放 → 旋转”有何不同？

特征值分解中，三步几何变换是旋转 (\mathbf{V}^{-1}) → 缩放 (\mathbf{A}) → 旋转 (\mathbf{V})。

奇异值分解中，三步几何变换是旋转 (\mathbf{V}^T) → 缩放 (\mathbf{S}) → 旋转 (\mathbf{U})。一个明显的区别是， \mathbf{V}^T 的旋转发生在 \mathbb{R}^D 空间， \mathbf{U} 的旋转则发生在 \mathbb{R}^n 空间。值得强调的是，这要求奇异分解为“完全型”。本书后续会介绍包括“完全型”在内的四种 SVD 分解。

几何视角

为了方便解释，我们用 2×2 矩阵 \mathbf{A} 做例子。

利用矩阵 \mathbf{A} 完成 $\mathbf{z} \rightarrow \mathbf{x}$ 线性映射，即 $\mathbf{x} = \mathbf{A}\mathbf{z}$ 。利用 SVD 分解，将 $\mathbf{A} = \mathbf{U}\mathbf{S}\mathbf{V}^T$ 代入映射运算得到：

$$\mathbf{A}\mathbf{z} = \mathbf{U} \mathbf{S} \mathbf{V}^T \begin{bmatrix} z_1 \\ z_2 \end{bmatrix} = \mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \quad (2)$$

Rotate Scale Rotate

图 1 所示为几何变换角度解释奇异值分解， \mathbf{A} 乘 \mathbf{x} ，相当于先用 \mathbf{V}^T 旋转，再用 \mathbf{S} 缩放，最后用 \mathbf{U} 旋转。




图 1. 几何角度解释奇异值分解

举个实例

下面用具体实例解释图 1。给定如下 2×2 矩阵 A ：

$$A = \begin{bmatrix} 1.625 & 0.6495 \\ 0.6495 & 0.875 \end{bmatrix} \quad (3)$$

对矩阵 A 进行 SVD 分解：

$$A = USV^T = \underbrace{\begin{bmatrix} 0.866 & -0.5 \\ 0.5 & 0.866 \end{bmatrix}}_U \underbrace{\begin{bmatrix} 2 & 0 \\ 0 & 0.5 \end{bmatrix}}_S \underbrace{\begin{bmatrix} 0.866 & -0.5 \\ 0.5 & 0.866 \end{bmatrix}}_{V^T} \quad (4)$$

即，

$$U = \begin{bmatrix} 0.866 & -0.5 \\ 0.5 & 0.866 \end{bmatrix}, \quad S = \begin{bmatrix} 2 & 0 \\ 0 & 0.5 \end{bmatrix}, \quad V = \begin{bmatrix} 0.866 & 0.5 \\ -0.5 & 0.866 \end{bmatrix} \quad (5)$$

▲ 注意，如果特征值分解和奇异值分解的对象都是可对角化矩阵，两个分解得到的结果等价。但是，奇异值分解的强大之处在于，任何实数矩阵都可以奇异值分解。

给定 e_1 和 e_2 两个单位向量：

$$e_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad e_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix} \quad (6)$$

e_1 和 e_2 经过 A 转换分别得到：

$$\begin{aligned} Ae_1 &= \begin{bmatrix} 1.625 & 0.6495 \\ 0.6495 & 0.875 \end{bmatrix} \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \begin{bmatrix} 1.625 \\ 0.6495 \end{bmatrix} \\ Ae_2 &= \begin{bmatrix} 1.625 & 0.6495 \\ 0.6495 & 0.875 \end{bmatrix} \begin{bmatrix} 0 \\ 1 \end{bmatrix} = \begin{bmatrix} 0.6495 \\ 0.875 \end{bmatrix} \end{aligned} \quad (7)$$

图 2 所示为转换前后的结果对比。请大家注意转换前后向量的方向和长度(模)的变化。




图 2. e_1 和 e_2 经过 A 线性转换

分步几何变换

(7) 等价于“旋转 (V^T) \rightarrow 缩放 (S) \rightarrow 旋转 (U)”，具体如图 3 所示。

e_1 和 e_2 两个向量先通过 V^T 进行旋转，得到：

$$\begin{aligned} V^T e_1 &= \begin{bmatrix} 0.866 & 0.5 \\ -0.5 & 0.866 \end{bmatrix} \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \begin{bmatrix} 0.866 \\ -0.5 \end{bmatrix} \\ V^T e_2 &= \begin{bmatrix} 0.866 & 0.5 \\ -0.5 & 0.866 \end{bmatrix} \begin{bmatrix} 0 \\ 1 \end{bmatrix} = \begin{bmatrix} 0.5 \\ 0.866 \end{bmatrix} \end{aligned} \quad (8)$$

在 (8) 基础上，再用对角矩阵 S 进行缩放，得到：

$$\begin{aligned}
 SV^T e_1 &= \begin{bmatrix} 2 & 0 \\ 0 & 0.5 \end{bmatrix} \begin{bmatrix} 0.866 \\ -0.5 \end{bmatrix} = \begin{bmatrix} 1.732 \\ -0.25 \end{bmatrix} \\
 SV^T e_2 &= \begin{bmatrix} 2 & 0 \\ 0 & 0.5 \end{bmatrix} \begin{bmatrix} 0.5 \\ 0.866 \end{bmatrix} = \begin{bmatrix} 1 \\ 0.433 \end{bmatrix}
 \end{aligned} \tag{9}$$

在之前“旋转 (V^T)”和“缩放 (S)”两步基础上，最后再利用 U 进行旋转，得到：

$$\begin{aligned}
 USV^T e_1 &= \begin{bmatrix} 0.866 & -0.5 \\ 0.5 & 0.866 \end{bmatrix} \begin{bmatrix} 1.732 \\ -0.25 \end{bmatrix} = \begin{bmatrix} 1.625 \\ 0.6495 \end{bmatrix} \\
 USV^T e_2 &= \begin{bmatrix} 0.866 & -0.5 \\ 0.5 & 0.866 \end{bmatrix} \begin{bmatrix} 1 \\ 0.433 \end{bmatrix} = \begin{bmatrix} 0.6495 \\ 0.875 \end{bmatrix}
 \end{aligned} \tag{10}$$

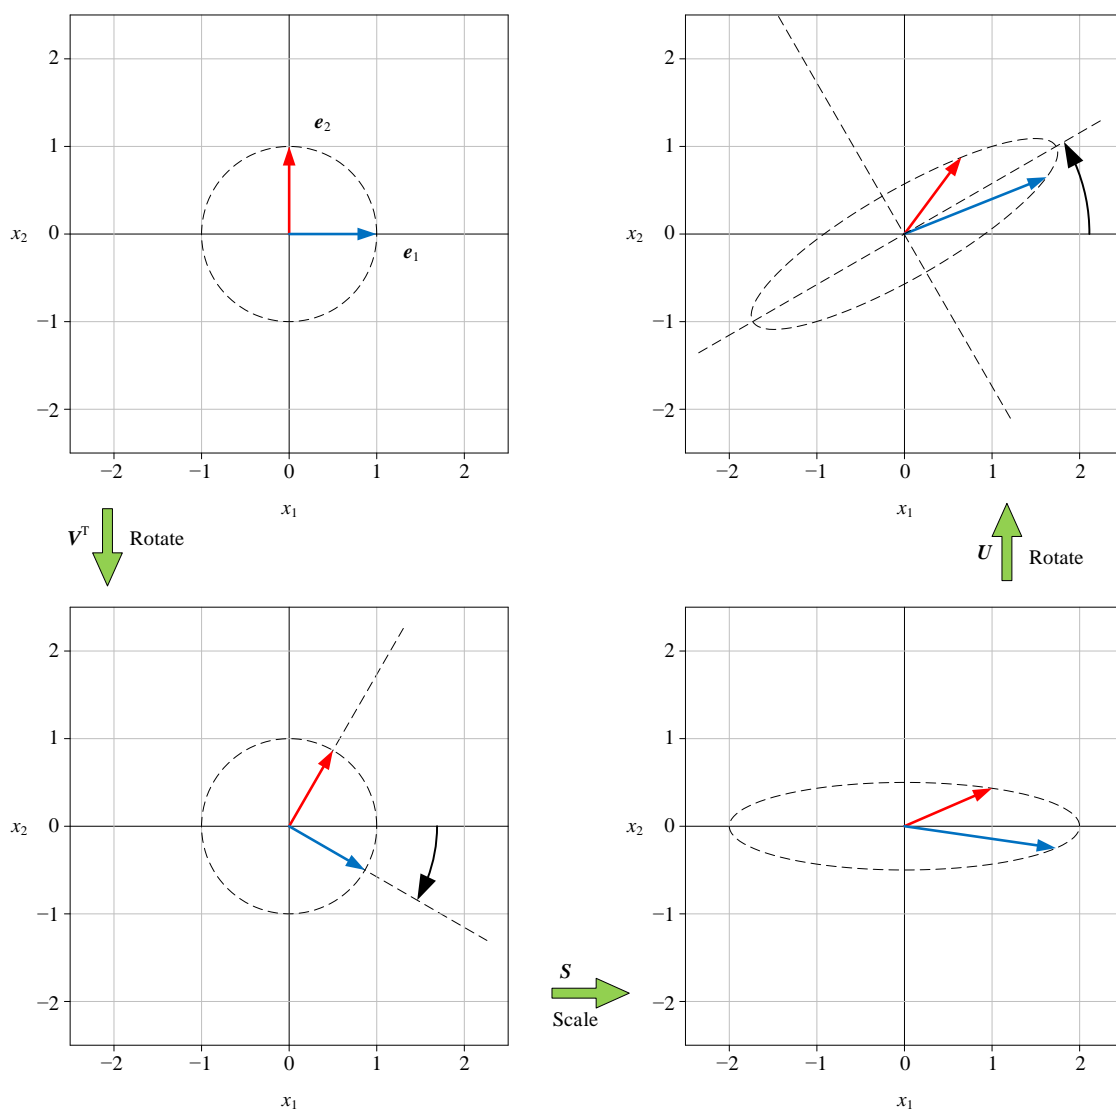


图 3. e_1 和 e_2 分别经过 V^T 、 S 和 U 转换



Bk4_Ch15_01.py 绘制图 3 所有子图。

15.2 不同类型 SVD 分解

SVD 分解分为**完全型** (full)、**经济型** (economy-size, thin)、**紧凑型** (compact) 和**截断型** (truncated) 四大类。

本节将简要介绍完全型和经济型两种奇异值分解之间的关系。下一章将深入讲解这四种 SVD 分解。

完全型

图 4 所示为完全型 SVD 分解热图，其中左奇异值矩阵 U 为方阵，形状为 $n \times n$ 。 S 的形状和 X 相同，为 $n \times D$ 。 S 的主对角线元素 s_j 为奇异值，具体形式为：

$$S = \begin{bmatrix} s_1 & & & \\ & s_2 & & \\ & & \ddots & \\ & & & s_D \end{bmatrix} \quad (11)$$

约定俗成，这 D 个奇异值的大小关系为 $s_1 \geq s_2 \geq \dots \geq s_D$ 。

如图 4 所示， S 可以分块为上下两个子块——对角方阵、全 0 矩阵 O 。





图 4. 矩阵 X 的完全型 SVD 分解

注意，一般情况，数据矩阵为“细高”长方形，偶尔大家也会见到“宽矮”长方形的数据矩阵。
(1) 中 \mathbf{X} 为细高长方形，对 \mathbf{X} 转置便得到宽矮长方形矩阵 \mathbf{X}^T 。如图 5 所示，相应的， \mathbf{X}^T 的 SVD 分解为：

$$\mathbf{X}^T = \mathbf{V} \mathbf{S}^T \mathbf{U}^T \quad (12)$$

图 5. 矩阵 \mathbf{X}^T 的完全型 SVD 分解

经济型

图 6 所示为经济型 SVD 分解结果热图。可以发现，左奇异值矩阵 \mathbf{U} 形状和 \mathbf{X} 相同，均为 $n \times D$ 。而 \mathbf{S} 为方阵，形状为 $D \times D$ 。从图 4 到图 6，利用的是分块矩阵乘法，这个话题留到下一章讨论。

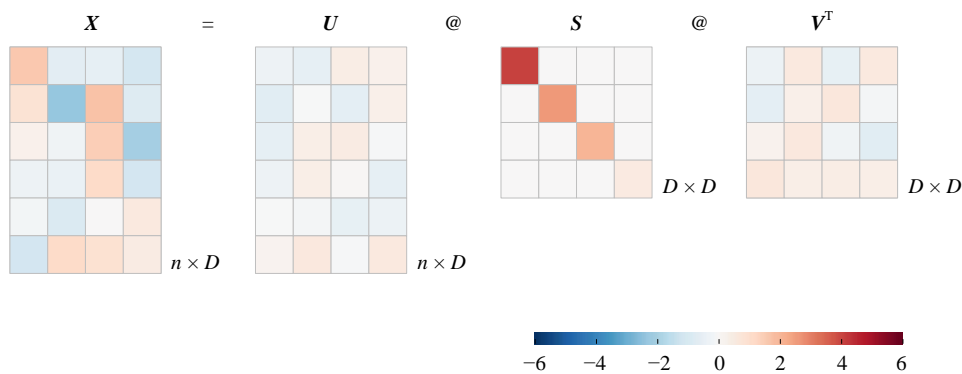


图 6. 经济型 SVD 分解

在经济型 SVD 分解中， \mathbf{S} 为对角方阵：

$$\mathbf{S} = \begin{bmatrix} s_1 & & & \\ & s_2 & & \\ & & \ddots & \\ & & & s_D \end{bmatrix} \quad (13)$$

当 \mathbf{S} 为对角方阵时，(12) 可以写成：

$$\mathbf{X}^T = \mathbf{V}\mathbf{S}\mathbf{U}^T \quad (14)$$



Bk4_Ch15_02.py 中 Bk4_Ch15_02_A 部分绘制图 4 和图 6。

15.3 左奇异向量矩阵 \mathbf{U}

\mathbf{U} 的列向量称作**左奇异向量** (left singular vector), \mathbf{U} 和自己转置 \mathbf{U}^T 的乘积为单位矩阵:

$$\mathbf{U}^T \mathbf{U} = \mathbf{I} \quad (15)$$

如图 7 所示, 对于完全型 SVD 分解, \mathbf{U} 为方阵。




图 7. \mathbf{U} 和自己转置 \mathbf{U}^T 的乘积为单位矩阵

特征值分解

本书前文提到过两次, 细高的长方形矩阵 \mathbf{X} 不能进行特征值分解。但是, 它的格拉姆矩阵 $\mathbf{X}^T \mathbf{X}$ 和 $\mathbf{X}\mathbf{X}^T$ 都是对称矩阵, 可以进行特征值分解。下面, 我们先分析 $\mathbf{X}\mathbf{X}^T$ 。

图 8 所示为 \mathbf{X} 和自己转置 \mathbf{X}^T 相乘得到第一个格拉姆矩阵 $\mathbf{X}\mathbf{X}^T$ 的热图, $\mathbf{X}\mathbf{X}^T$ 为 $n \times n$ 方阵。


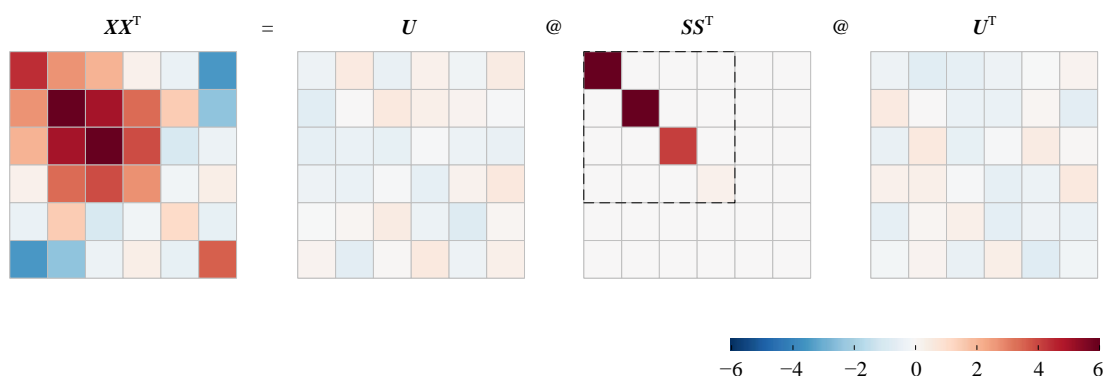


图 8. X 和自己转置 X^T 的乘积热图

对方阵 XX^T 进行特征值分解，可以发现 U 的列向量是特征向量，而 SS^T 是 XX^T 的特征值矩阵：

$$\begin{aligned} XX^T &= (USV^T)(USV^T)^T \\ &= US(V^TV)S^TU^T \\ &= USS^TU^T \end{aligned} \quad (16)$$

图 9 所示为 X^TX 特征值分解热图。

图 9. 对 X^TX 特征值分解

SS^T 主对角线为特征值，对 SS^T 展开得到：

$$SS^T = \begin{bmatrix} s_1 & & & \\ & s_2 & & \\ & & \ddots & \\ & & & s_D \\ & & & & 0 \\ & & & & & 0 \end{bmatrix} \begin{bmatrix} s_1 & & & \\ & s_2 & & \\ & & \ddots & \\ & & & s_D \end{bmatrix} = \begin{bmatrix} s_1^2 & & & \\ & s_2^2 & & \\ & & \ddots & \\ & & & s_D^2 \\ & & & & 0 \\ & & & & & 0 \end{bmatrix} = \begin{bmatrix} \lambda_1 & & & \\ & \lambda_2 & & \\ & & \ddots & \\ & & & \lambda_D \\ & & & & \lambda_n \end{bmatrix} \quad (17)$$


观察上式，发现当 $j = 1 \sim D$ 时，特征值 λ_j 和奇异值 s_j 存在如下关系：

$$\lambda_j = s_j^2 \quad (18)$$

剩余的特征值均为 0。

向量空间

如图 10 所示， XX^T 进行特征值分解得到正交矩阵 $U = [u_1, u_2, \dots, u_n]$ 是个规范正交基，张起的空间为 \mathbb{R}^n 。

图 10. 对 Gram 矩阵 XX^T 特征值分解得到规范正交基 U

类比 QR 分解

数据矩阵 X 进行 QR 分解得到：

$$X = QR \quad (19)$$

对于完全型 QR 分解， Q 为正交矩阵，也是一个规范正交基 $[q_1, q_2, \dots, q_D]$ 。

对 X 进行完全型 SVD 分解，把结果写成：

$$X = U(SV^T) \quad (20)$$

对比 (19) 和 (20)， Q 和 U 都是正交矩阵，形状虽然相同，但是两者显然是不同的规范正交基。

对于 QR 分解， x_1 和 q_1 平行。打个比方， x_1 像是一个锚，确定了 $[q_1, q_2, \dots, q_D]$ 的空间位置。

而 SVD 分解则引入了一个优化视角——逐个最大化奇异值。本书第 18 章将深入介绍这个优化视角。

对比 (19) 和 (20)， R 则对应 SV^T 。特别地， SV^T 结果正交，即 $SV^T(SV^T)^T = SV^TVS^T = SS^T$ 。



Bk4_Ch15_02.py 中 Bk4_Ch15_02_B 部分绘制图 7。请读者自行编写代码绘制图 8 和图 9。

15.4 右奇异向量矩阵 V

V 的列向量称作**右奇异向量** (right singular vector)， V 和其转置 V^T 的乘积也是单位矩阵：

$$V^TV = I \quad (21)$$

图 11 所示为上式运算对应热图。

值得强调的是，凡是满足 $V^T V = V V^T = I$ 的方阵 V 都是**正交矩阵** (orthogonal matrix)，对应规范正交基。但是，并不是所有正交矩阵都是**旋转矩阵** (rotation matrix)。只有 $\det(V) = 1$ 的正交矩阵才叫旋转矩阵，这种矩阵也叫**特殊正交矩阵** (special orthogonal matrix)。

而一般正交矩阵的行列式值为 ± 1 ，即 $\det(V) = \pm 1$ 。当 $\det(V) = -1$ 时， V 对应的几何操作为“旋转 + 镜像”。这也告诉我们，SVD 分解中 V 和 U 并不唯一， V 和 U 的列向量都可以取负。当 $\det(V) = \det(U) = -1$ 时， V 和 U 都是“旋转 + 镜像”。但是为了方便，完全型 SVD 结果中的 V 和 U ，我们还是管它们的几何操作叫“旋转”。




图 11. V 和其转置 V^T 的乘积也是单位矩阵

特征值分解

图 12 所示为转置 X^T 和 X 相乘得到第二个格拉姆矩阵 $X^T X$ 的热图， $X^T X$ 为 $D \times D$ 方阵。





图 12. 转置 X^T 和 X 乘积热图

对 $X^T X$ 特征值分解得到：

$$\begin{aligned} X^T X &= (USV^T)^T (USV^T) \\ &= VS^T (U^T U) SV^T \\ &= VS^T SV^T \end{aligned} \quad (22)$$

V 是 $X^T X$ 的特征向量矩阵， $S^T S$ 为特征值矩阵。图 13 所示为对 $X^T X$ 进行特征值分解热图。

图 13. 对 $X^T X$ 进行特征值分解

如图 14 所示，对 $X^T X$ 进行特征值分解， $S^T S$ 为特征值矩阵，奇异值和特征值也存在如下平方关系：

$$S^T S = \begin{bmatrix} s_1^2 & & & \\ & s_2^2 & & \\ & & \ddots & \\ & & & s_D^2 \end{bmatrix} = \begin{bmatrix} \lambda_1 & & & \\ & \lambda_2 & & \\ & & \ddots & \\ & & & \lambda_D \end{bmatrix} \quad (23)$$

比较 (17) 和 (23)，我们容易发现两个不同格拉姆矩阵特征值之间的关系。



本书第 24 章将总结分解对象不同时，奇异值和特征值之间的联系和差异。






图 14. 奇异值和特征值之间关系

向量空间

如图 10 所示， $X^T X$ 进行特征值分解得到正交矩阵 $V = [v_1, v_2, \dots, v_D]$ ，它也是个规范正交基，张起的空间为 \mathbb{R}^D 。

奇异值分解不但可以分解各种形状实数矩阵，并且一次性获得 $U = [u_1, u_2, \dots, u_n]$ 和 $V = [v_1, v_2, \dots, v_D]$ 两个规范正交基。

图 15. 对 Gram 矩阵 $X^T X$ 特征值分解得到规范正交基 V 

Bk4_Ch15_02.py 中 Bk4_Ch15_02_C 部分绘制图 11。请读者自行编写代码绘制图 12 和图 13。

15.5 两个视角：投影和数据叠加

本节用两个视角观察 SVD 分解。这两个视角对应两种不同的矩阵乘法展开方式。

投影

对于经济型 SVD 分解，将 (1) 等式左右两侧右乘 V ，可以得到：

$$X_{n \times D} V = US \quad (24)$$

将 V 和 U 本身分别写成左右排列的列向量：

$$X_{n \times D} \begin{bmatrix} v_1 & v_2 & \cdots & v_D \end{bmatrix} = \begin{bmatrix} u_1 & u_2 & \cdots & u_D \end{bmatrix} \begin{bmatrix} s_1 & & & \\ & s_2 & & \\ & & \ddots & \\ & & & s_D \end{bmatrix} \quad (25)$$

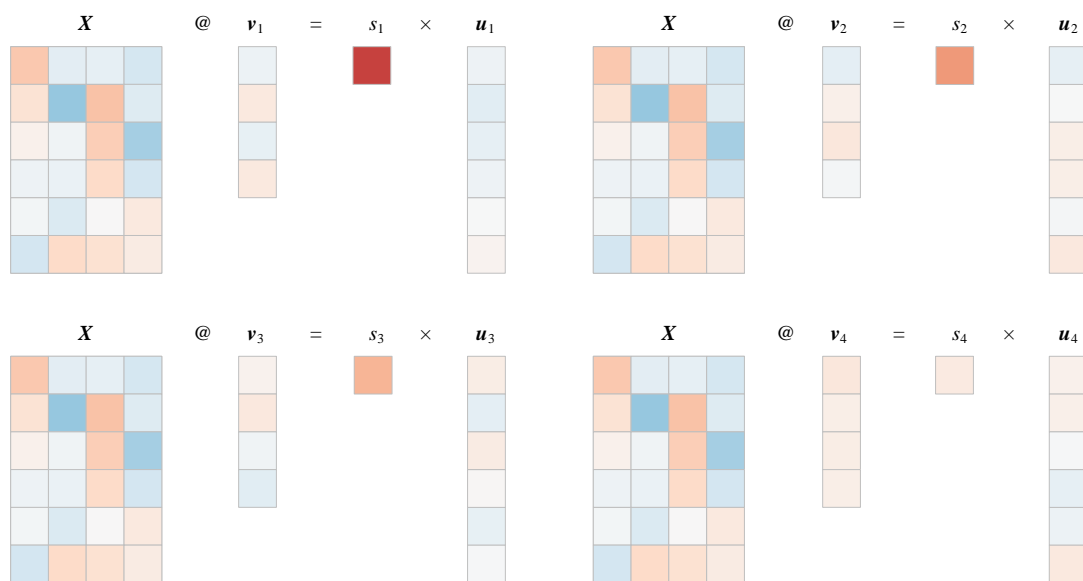
(25) 进一步展开得到：

$$\begin{bmatrix} Xv_1 & Xv_2 & \cdots & Xv_D \end{bmatrix} = \begin{bmatrix} s_1 u_1 & s_2 u_2 & \cdots & s_D u_D \end{bmatrix} \quad (26)$$

因此，

$$Xv_j = s_j u_j \quad (27)$$

上式可以理解为 X 向 v_j 投影，结果为 $s_j u_j$ 。对应运算热图如图 16 所示。注意， v_j 和 u_j 都是单位向量，即两者的模都是 1。从另外一个角度来看， v_j 和 u_j 都不含单位，而 X 和 s_j 含有单位。

图 16. X 向 v_j 映射结果为 $s_j u_j$

(27) 左右都是向量，等式两侧分别求模，即 L^2 范数，得到：

$$\|Xv_j\| = \|s_j u_j\| = s_j \|u_j\| = s_j \quad (28)$$

也就是说 Xv_j 的模为对应奇异值 s_j 。由于奇异值 s_1 到 s_4 从大到小排列，也就是说 Xv_1 的模最大。这个角度对于理解[主成分分析](#) (principal component analysis, PCA) 极为重要。

叠加

第二种展开方式如下：

$$\begin{aligned} X_{n \times D} &= [u_1 \quad u_2 \quad \cdots \quad u_D] \begin{bmatrix} s_1 & & & \\ & s_2 & & \\ & & \ddots & \\ & & & s_D \end{bmatrix} \begin{bmatrix} v_1^T \\ v_2^T \\ \vdots \\ v_D^T \end{bmatrix} \\ &= [s_1 u_1 \quad s_2 u_2 \quad \cdots \quad s_D u_D] \begin{bmatrix} v_1^T \\ v_2^T \\ \vdots \\ v_D^T \end{bmatrix} = s_1 u_1 v_1^T + s_2 u_2 v_2^T + \cdots + s_D u_D v_D^T \end{aligned} \quad (29)$$

举个例子，对于 $D=4$ 时：

$$X = s_1 u_1 v_1^T + s_2 u_2 v_2^T + s_3 u_3 v_3^T + s_4 u_4 v_4^T \quad (30)$$

(30) 中奇异值 s_1 到 s_4 从大到小排列，即 $s_1 \geq s_2 \geq s_3 \geq s_4$ 。

▲ 注意， $s_j \mathbf{u}_j \mathbf{v}_j^T$ 的秩为 1。

如图 17 所示，可以发现对应 (30) 等式右侧从左到右的四项相当于逐步还原 \mathbf{X} 。特别地，请大家注意图 17 左侧四幅热图由上到下颜色逐渐变浅。下一章会深入介绍通过叠加替换原始数据矩阵。




图 17. 四幅热图叠加还原原始图像

张量积

再进一步，利用 (27) 给出的关系，我们将 (30) 写成张量积之和的形式：

$$\begin{aligned}
 \mathbf{X} &= s_1 \mathbf{u}_1 \mathbf{v}_1^T + s_2 \mathbf{u}_2 \mathbf{v}_2^T + s_3 \mathbf{u}_3 \mathbf{v}_3^T + s_4 \mathbf{u}_4 \mathbf{v}_4^T \\
 &= \mathbf{X} \mathbf{v}_1 \mathbf{v}_1^T + \mathbf{X} \mathbf{v}_2 \mathbf{v}_2^T + \mathbf{X} \mathbf{v}_3 \mathbf{v}_3^T + \mathbf{X} \mathbf{v}_4 \mathbf{v}_4^T \\
 &= \mathbf{X} (\mathbf{v}_1 \mathbf{v}_1^T + \mathbf{v}_2 \mathbf{v}_2^T + \mathbf{v}_3 \mathbf{v}_3^T + \mathbf{v}_4 \mathbf{v}_4^T) \\
 &= \mathbf{X} (\mathbf{v}_1 \otimes \mathbf{v}_1 + \mathbf{v}_2 \otimes \mathbf{v}_2 + \mathbf{v}_3 \otimes \mathbf{v}_3 + \mathbf{v}_4 \otimes \mathbf{v}_4)
 \end{aligned} \tag{31}$$

这就是本书第 10 章讲解的“二次投影”再“层层叠加”。

➡ 能完成类似 (31) 投影的规范正交基有无数组，为什么 $\mathbf{V} = [\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_D]$ 脱颖而出？ \mathbf{V} 的特殊性体现在哪？回答这个问题需要优化方面的知识，这是本书第 18 章要探讨的话题。



Bk4_Ch15_02.py 中 Bk4_Ch15_02_D 部分绘制本节图像。




图 18 四幅子图总结本章主要内容。请大家特别注意，奇异值分解对应“旋转 → 缩放 → 旋转”，不同于特征值分解的“旋转 → 缩放 → 旋转”。

任何实数矩阵都可以进行奇异值分解，但是只有可对角矩阵才能进行特征值分解。此外，奇异值分解得到的两个正交矩阵 U 和 V 一般形状不同。

请大家注意，特征值和奇异值之间的关系。格拉姆矩阵是奇异值分解和特征值分解的桥梁，这一点本书后续还要反复提到。




图 18. 总结本章重要内容的四幅图



数值线性代数是本书完全没有涉及的板块。

本书有关矩阵分解这个版块介绍了 LU 分解、Cholesky 分解、QR 分解、特征值分解、奇异值分解等等原理和应用，也介绍如何利用 Python 函数完成矩阵分解。但是本书没有提到计算机如何完成这些矩阵分解，也就是 Python 库中这些函数的底层算法实现，这就是数值线性代数研究的问题。

大家如果对这个话题感兴趣的话，可以参考 Holger Wendland 的 *Numerical Linear Algebra: An Introduction*。